Estudiantes: Samuel Alvarez, Alejandro Muñoz

Sistema de recomendación (MovieLens 1M)

Este trabajo se implementó en dos partes que se conectan entre sí:

1. **Proceso batch en Spark**: segmenta usuarios con **K-Means** usando features simples (actividad y promedio de rating) y genera **recomendaciones por usuario** basadas en su cluster.
2. **API en FastAPI**: consume un **JSON** generado a partir de la salida del proceso de Spark y expone endpoints para consultar recomendaciones por usuario o para todos los usuarios.

La idea es separar el cómputo pesado (clustering + recomendaciones) del consumo en tiempo real (consultas vía API).

Implementación 1: Clustering y recomendaciones con Spark (K-Means)

Archivo: `spark-kmeans.py`

Objetivo

- **Clustering**: agrupar usuarios de MovieLens 1M en K segmentos usando K-Means.
- **Recomendación por cluster**: recomendar películas a cada usuario según las películas mejor valoradas/populares en su cluster, **excluyendo** las ya vistas por el usuario.
- **Evaluación**: medir calidad con **Precision@K** y **Recall@K** con un split train/test.

Entradas

- `ratings.dat` con formato `UserID::MovieID::Rating::Timestamp`
- `movies.dat` con formato `MovieID::Title::Genres`

El script soporta dataset local (carpeta `ml-1m`) o ruta `gs://`.

Carga de datos (local y GCS con fallback)

- `load_ratings()` y `load_movies()` leen localmente con `spark.read.text(...)` y luego separan por `::`.
- Si el path comienza con `gs://`, intenta leer directo desde Spark.
- Si no es posible (conector/permiso), hace **fallback**:
  - el driver descarga `ratings.dat` / `movies.dat` con `gcloud storage cp`
  - se leen con Pandas y luego se crea el DataFrame en Spark (`spark.createDataFrame(...)`).

Features usadas para el clustering

Se construyen features por usuario con `build_user_features()`:

- `movies_rated`: cantidad de películas calificadas (actividad)
- `avg_rating`: promedio del rating que el usuario suele dar (tendencia/sesgo)

Luego `scale_features()` arma el vector y estandariza:

- `VectorAssembler` → `features_raw`
- `StandardScaler(withMean=True, withStd=True)` → `features`

Esto es importante porque K-Means es sensible a escala.

Entrenamiento K-Means y asignación de clusters

Para cada valor de K (configurable por `--k-values`), `generate_recommendations_for_k()`:

1. Entrena `KMeans(featuresCol="features", k=K)`
2. Asigna cluster a cada usuario (`prediction` → `cluster`)
3. Calcula estadísticas por cluster (`cluster_stats`):
    - `avg_movies_rated`
    - `avg_user_rating`
    - `num_users`
4. Agrega una interpretación simple del cluster con `describe_cluster()`.

Construcción de recomendaciones por usuario

La recomendación se construye en dos niveles:

1. **Score por película dentro del cluster** (`cluster_movie_scores`)
    - Se une `train_ratings` con el cluster del usuario.
    - Se agrupa por `(cluster, movieId)`.
    - Se calcula:
        - `cluster_avg_movie_rating` = promedio de ratings en ese cluster
        - `cluster_rating_count` = cantidad de ratings en ese cluster
    - Se define un score final:

$$ score = cluster_avg_movie_rating \times \log(1 + cluster_rating_count) $$

La parte `log(1 + count)` evita que una película con muchísimos votos “domine” de forma excesiva, pero igual premia el soporte.

2. **Recomendación final por usuario**
    - Para cada usuario se toman las películas candidatas del cluster.
    - Se eliminan las ya vistas/calificadas en train con un `left_anti join` contra `seen_movies`.
    - Se rankea por usuario con una ventana `Window.partitionBy("userId")` ordenando por:
        1. `recommendation_score` desc
        2. `cluster_rating_count` desc
        3. `movieId` asc (desempate estable)
    - Se queda con el **Top-N** configurado (`--top-n`).

Evaluación (Precision@K / Recall@K)

La función `evaluate_recommendations()`:

- Define “relevante” en test si `rating >= relevance_threshold` (por defecto 4.0)
- Calcula:

    - `hits(u)`: recomendaciones top-N que aparecen como relevantes en test
    - `precision@k(u) = hits(u) / N`
    - `recall@k(u) = hits(u) / relevant_count(u)`
- Devuelve métricas:
    - `global_metrics`: promedio de precision/recall y usuarios evaluados
    - `per_user_metrics`: métricas por usuario

Salidas (export a JSON)

Para cada K se escribe en `--output-dir` una carpeta `k=K/` con:

- `user_clusters/` (cluster por usuario)
- `cluster_stats/`
- `cluster_genres/` (conteos de géneros por cluster)
- `recommendations_topn/` (recomendaciones top-N)
- `sample_recommendations_20_users/`
- `per_user_metrics/`
- `metrics/` (métricas globales para ese K)

Además se genera `metrics_summary/` para comparar configuraciones de K.

Nota: `DataFrame.write.json(...)` en Spark genera un **directorio** con varios `part-*.json` (no un único archivo JSON).

Implementación 2: API de recomendaciones (FastAPI)

Archivo: `api_recommendation.py`

Objetivo

Exponer un servicio HTTP para consultar recomendaciones ya calculadas, evitando recomputar clustering/recomendaciones cada vez.

¿Cómo se conecta con el proceso de Spark?

La API carga al iniciar un archivo **`recommendations_api.json`** que se construye a partir de la salida del pipeline de Spark.

- El JSON se generó de forma completa para el dataset **MovieLens 1M**, incluyendo a **todos los 6040 usuarios**.
- El JSON queda en un formato “amigable para API”, por usuario, por ejemplo:

```
{
    "user_id": 1,
    "cluster": 2,
    "recommendations": [
        {"movie_id": 123, "movie_title": "Toy Story (1995)", "score": 6.42}
```

```
    ]
}
```

Donde `score` corresponde al score calculado en Spark (ej. `recommendation_score`).

Modelos y carga en memoria

- `Recommendation`: (`movie_id`, `movie_title`, `score`)
- `UserRecommendations`: (`user_id`, `cluster`, `recommendations`)

Al iniciar, la API lee `recommendations_api.json` y construye un diccionario `db`:

- **key**: `user_id`
- **value**: objeto `UserRecommendations`

Esto permite responder consultas rápido (lookup O(1) por usuario).

Endpoints

- `GET /`
  - Devuelve info básica y cuántos usuarios fueron cargados.
- `GET /recommendations?limit=100&offset=0`
  - Devuelve recomendaciones para todos los usuarios (paginado simple con `limit` y `offset`).
- `GET /recommendations/{user_id}`
  - Devuelve recomendaciones para un usuario específico.
  - **Manejo de error**: si el usuario no existe en `db`, responde `404` con el mensaje `Usuario {user_id} no encontrado`.
- `GET /health`
  - Endpoint de salud para validar que la API está corriendo y cuántos usuarios cargó.

Ejecución

Ejemplo recomendado:

```
uvicorn api_recommendation:app --host 0.0.0.0 --port 8000
```

Implementación 3: Frontend (Dashboard web)

Carpeta: `frontend/`

Objetivo

Proveer una interfaz web simple para:

- Verificar si la API está disponible.
- Consultar recomendaciones para un usuario específico.
- Listar usuarios y explorar recomendaciones de forma rápida.
- Visualizar la respuesta JSON (útil para validación/demostración).

¿Cómo se conecta con la API?

El frontend es **estático** (HTML/CSS/JS) y consume la API con `fetch()`.

- La URL base se configura en `frontend/js/app.js` mediante `API_BASE_URL`.
- Los endpoints consumidos son:
  - `GET /health` (estado de la API)
  - `GET /recommendations/{user_id}` (consulta por usuario)
  - `GET /recommendations` (listado general, con paginado en la API)

Flujo de uso en la UI

1. Al cargar la página (`DOMContentLoaded`):
   - se ejecuta `checkAPIStatus()` para mostrar **API Online/Offline**.
   - se ejecuta `loadAllUsers()` para traer un listado inicial.
2. Búsqueda por usuario:
   - `searchUser()` toma el `userId` del input y consulta `GET /recommendations/{user_id}`.
   - Si existe, `displayUserResult()` renderiza tarjetas con el Top-N de películas.
   - Si no existe, se muestra un mensaje de error (por ejemplo, usuario no encontrado).
3. Listado general:
   - `loadAllUsers()` consulta `GET /recommendations` y muestra el listado con `displayAllUsers()`.
   - Al hacer clic en un usuario del listado, se llama `searchUserById(user_id)`.
4. Estadísticas rápidas:
   - `updateStats()` calcula y muestra métricas de UI como total de usuarios, total de recomendaciones y rango de clusters.

Evidencia que se muestra

La evidencia del frontend incluye:

- Dashboard consultando un usuario específico.
- Dashboard listando todos los usuarios.
- Manejo de error cuando se consulta un usuario inexistente.

Evidencia / capturas

Las siguientes imágenes muestran resultados del proceso (clusters, métricas y ejemplos de recomendaciones):

end point de get para un usuario especifico

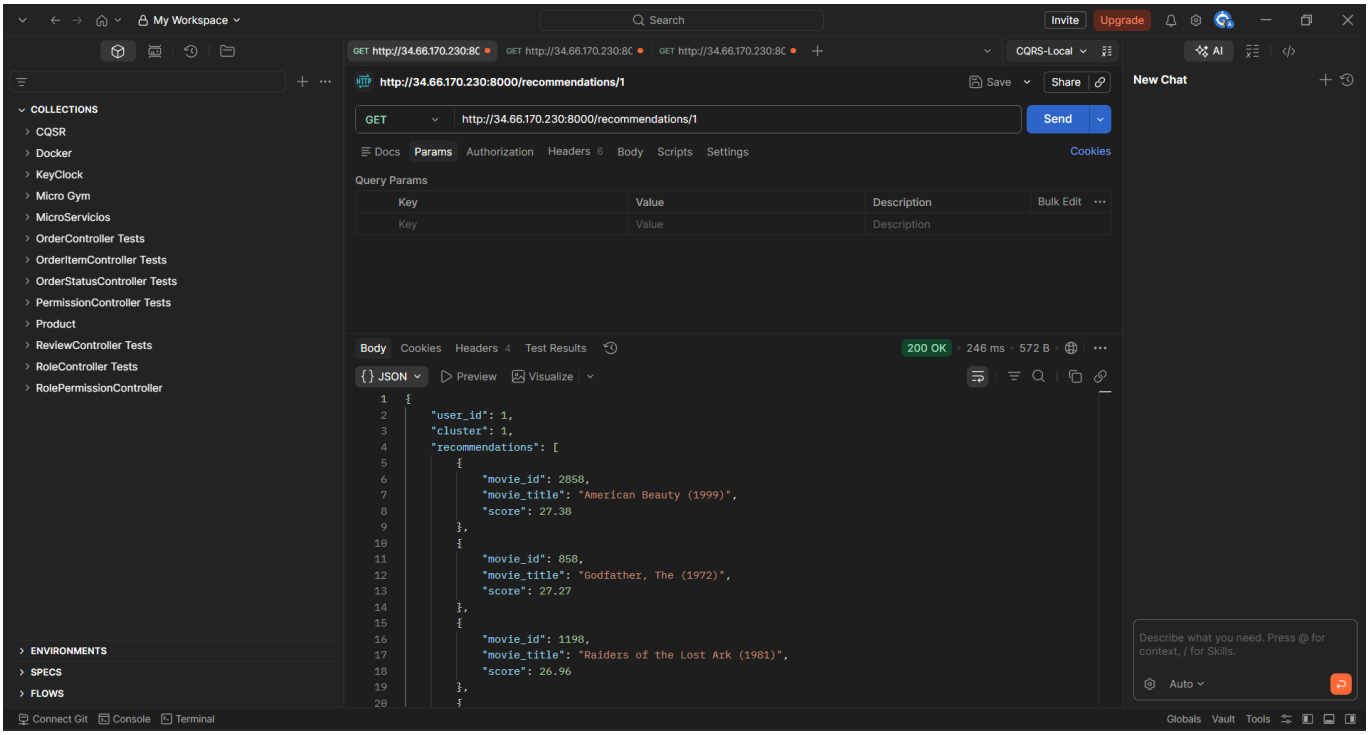

end point de get para todos los usuarios

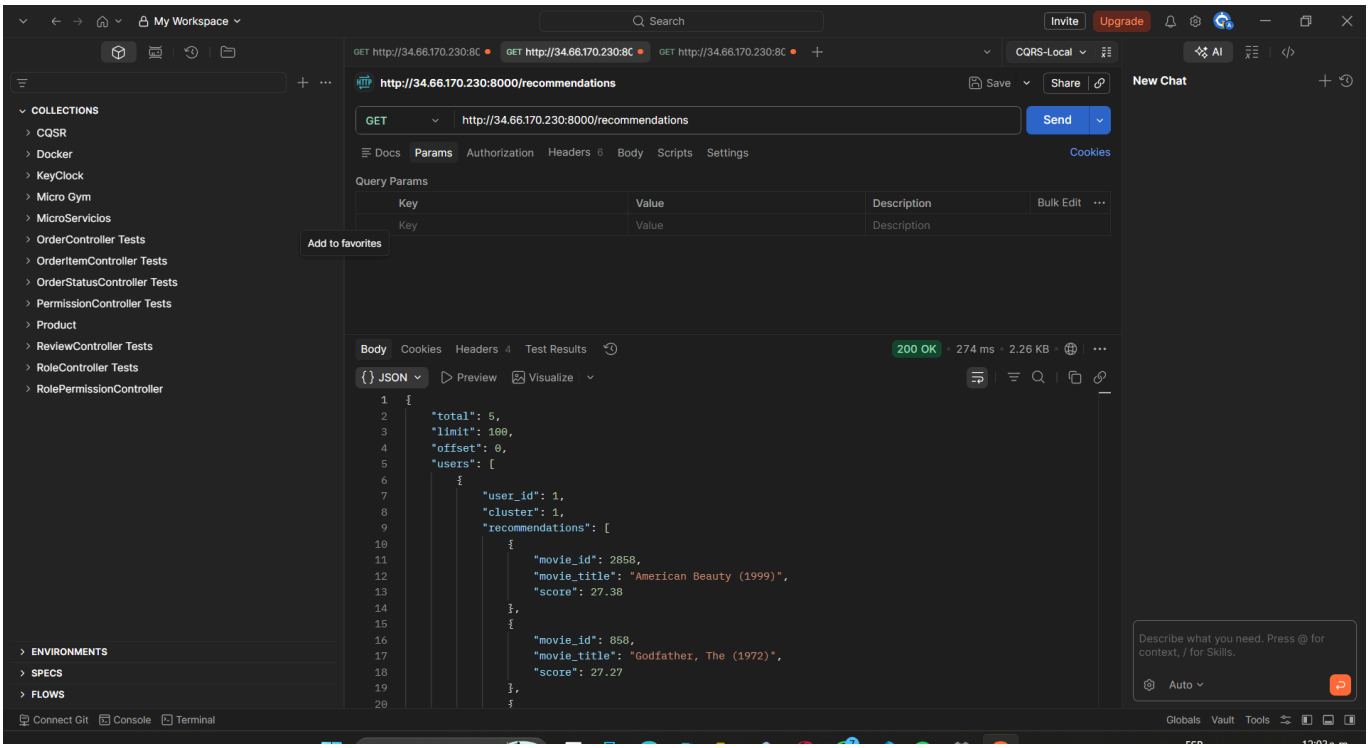

end point de get manejo de errores de not found

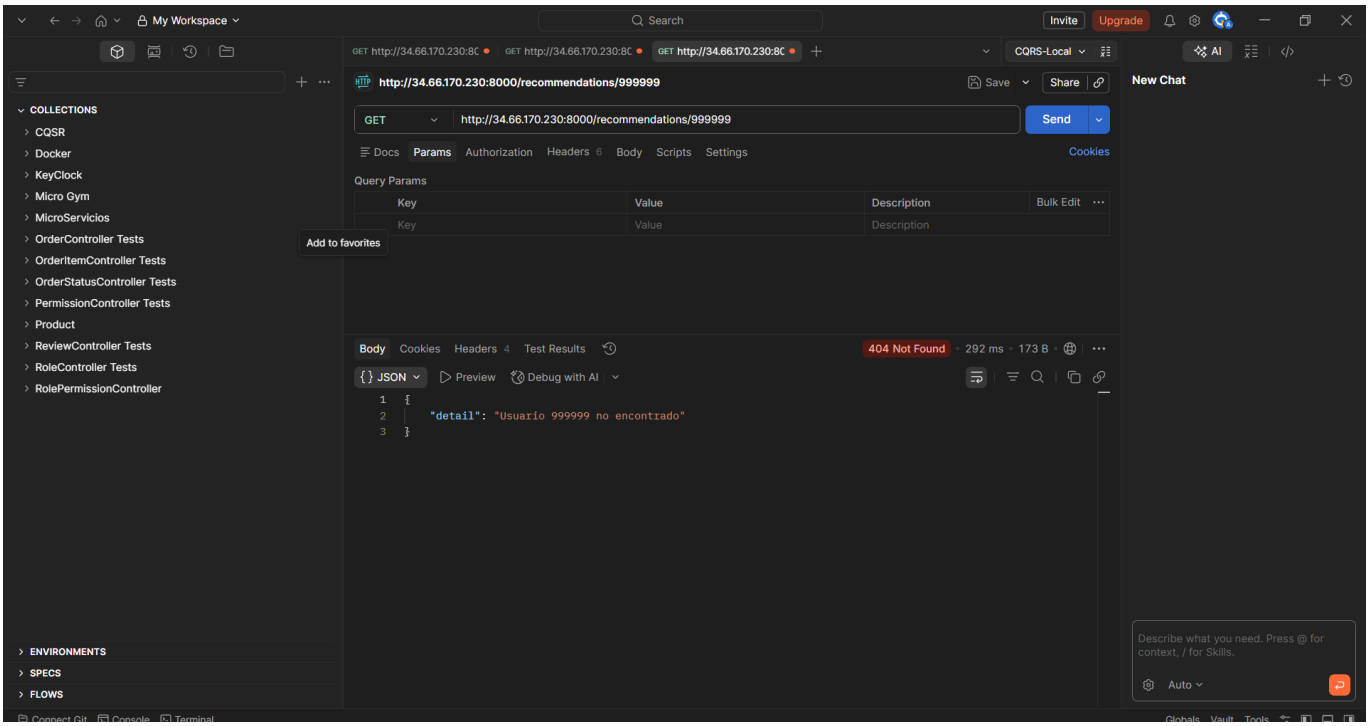

backend todos los archivos en la vm

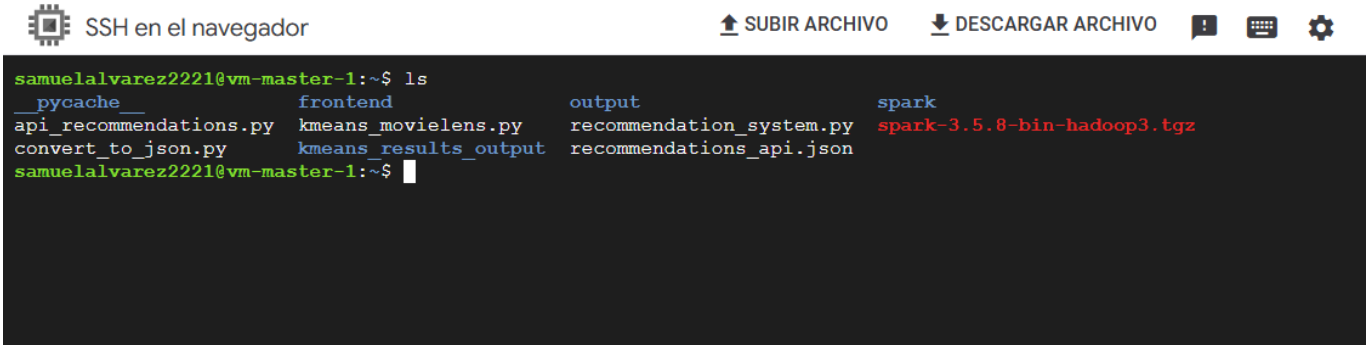

backend corriendo en mi vm master

ssh.cloud.google.com/v2/ssh/projects/eco-microservices-dev/zones/us-central1-f/instances/vm-master-1

SSH en el navegador SUBIR ARCHIVO DESCARGAR ARCHIVO

```
@app.get("/")
def root():
    return {"api": "Movie Recommendations", "total_users": len(db)}

@app.get("/recommendations")
def get_all(limit: int = 100, offset: int = 0):
    users = list(db.values())
    return {
        "total": len(users),
        "limit": limit,
        "offset": offset,
        "users": [u.dict() for u in users[offset:offset+limit]]
    }

@app.get("/recommendations/{user_id}")
def get_user(user_id: int):
    if user_id not in db:
        raise HTTPException(404, f"Usuario {user_id} no encontrado")
    return db[user_id]

@app.get("/health")
def health():
    return {"status": "ok", "users_loaded": len(db)}

if __name__ == "__main__":
    import uvicorn
    uvicorn.run("api_recommendations:app", host="0.0.0.0", port=8000)
samuelalvarez2221@vm-master-1:~$ python3 api_recommendations.py
Cargados 5 usuarios
Cargados 5 usuarios
INFO:     Started server process [8616]
INFO:     Waiting for application startup.
INFO:     Application startup complete.
INFO:     Uvicorn running on http://0.0.0.0:8000 (Press CTRL+C to quit)
INFO:     190.99.146.145:47680 - "GET /recommendations/1 HTTP/1.1" 200 OK
INFO:     190.99.146.145:47680 - "GET /recommendations HTTP/1.1" 200 OK
INFO:     190.99.146.145:47680 - "GET /recommendations/999999 HTTP/1.1" 404 Not Found
```

front corriendo en la vm master

SSH en el navegador SUBIR ARCHIVO DESCARGAR ARCHIVO

```
Linux vm-master-1 6.1.0-44-cloud-amd64 #1 SMP PREEMPT_DYNAMIC Debian 6.1.164-1 (2026-03-09) x86_64

The programs included with the Debian GNU/Linux system are free software;
the exact distribution terms for each program are described in the
individual files in /usr/share/doc/*/copyright.

Debian GNU/Linux comes with ABSOLUTELY NO WARRANTY, to the extent
permitted by applicable law.
Last login: Wed Apr 29 23:27:21 2026 from 35.235.245.130
samuelalvarez2221@vm-master-1:~$ ls
__pycache__             frontend                output                  spark
api_recommendations.py  kmeans_movielens.py     recommendation_system.py  spark-3.5.8-bin-hadoop3.tgz
convert_to_json.py      kmeans_results_output   recommendations_api.json
samuelalvarez2221@vm-master-1:~$ cd frontend
samuelalvarez2221@vm-master-1:~/frontend$ python3 -m http.server 8081
Serving HTTP on 0.0.0.0 port 8081 (http://0.0.0.0:8081/) ...
186.147.148.177 - - [29/Apr/2026 23:29:39] "GET / HTTP/1.1" 304 -
186.147.148.177 - - [29/Apr/2026 23:29:40] "GET /css/styles.css HTTP/1.1" 304 -
186.147.148.177 - - [29/Apr/2026 23:29:40] "GET /js/app.js HTTP/1.1" 304 -
```

dashboard del front mostrando un get de un usuario especifico

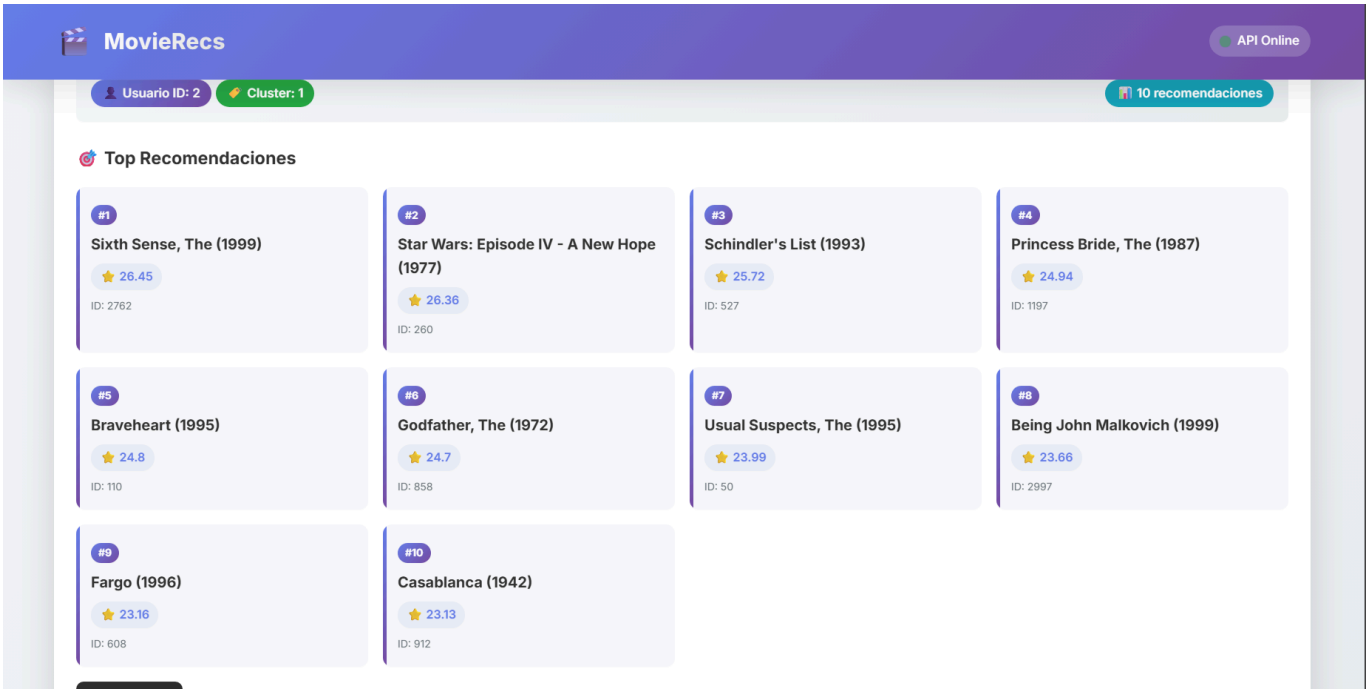

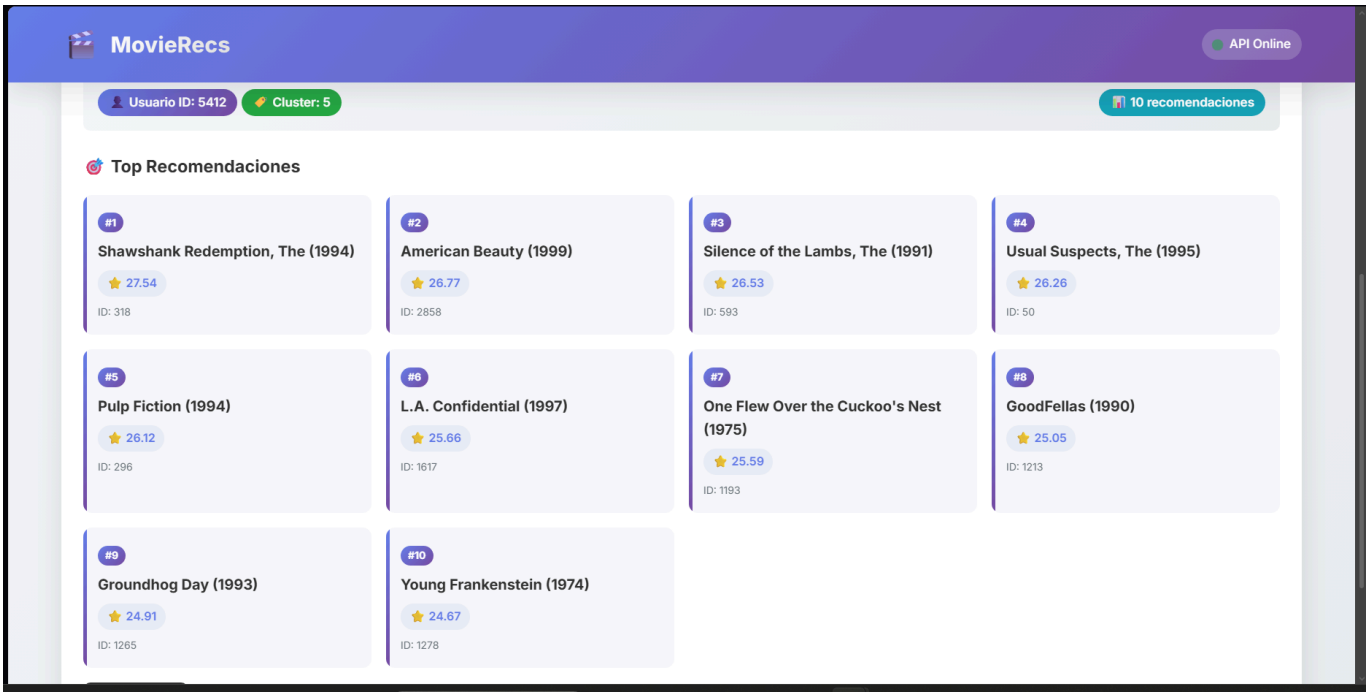

dashboard del front mostrando todos los usuarios

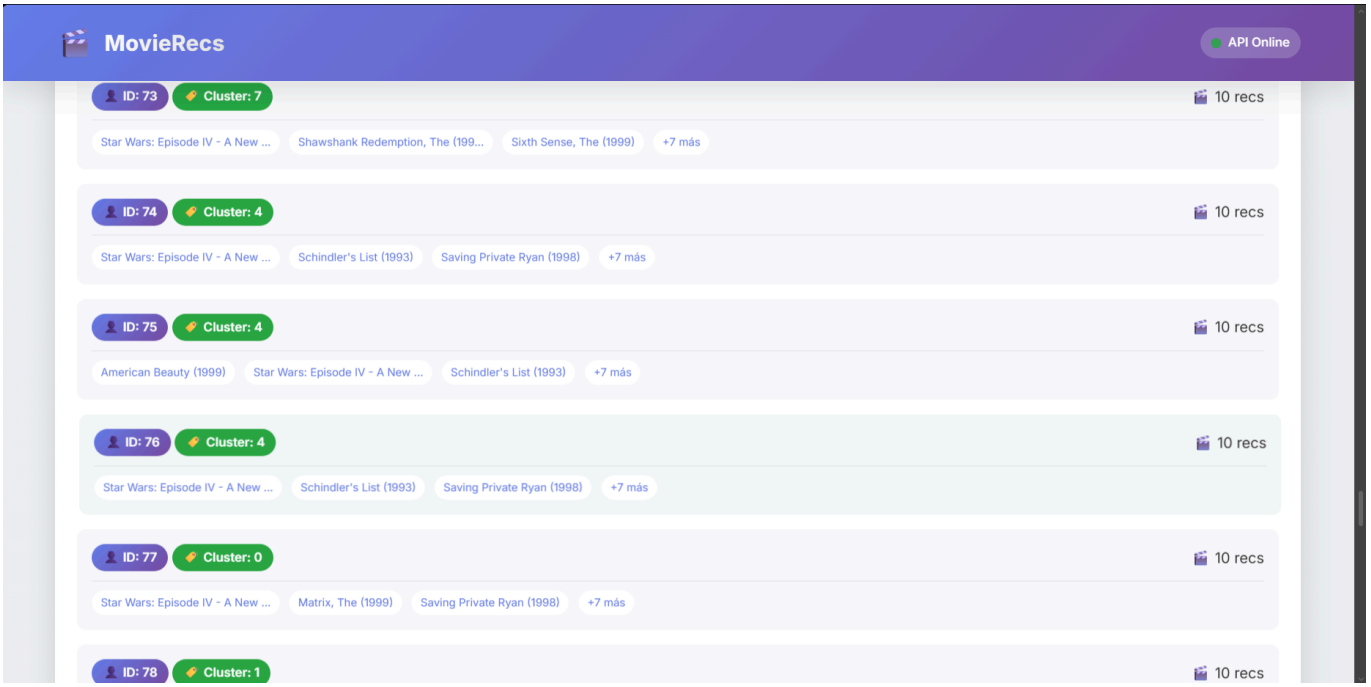

dashboard del front mostrando uno que no existe para manejo de errores

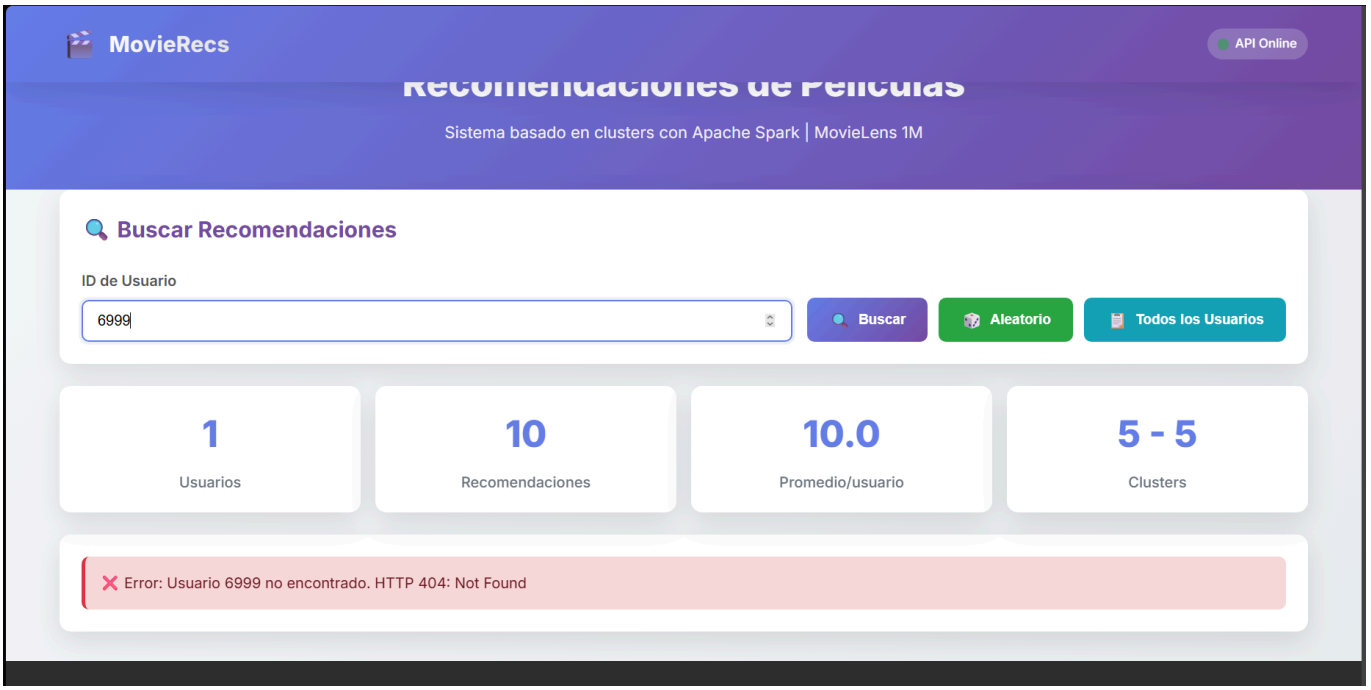
MovieRecs
API Online
Recomendaciones de Películas
Sistema basado en clusters con Apache Spark | MovieLens 1M
Buscar Recomendaciones
ID de Usuario
6999
Buscar
Aleatorio
Todos los Usuarios
1
Usuarios
10
Recomendaciones
10.0
Promedio/usuario
5 - 5
Clusters
Error: Usuario 6999 no encontrado. HTTP 404: Not Found